

# حل یک کار طبقه بندی با پین کردن شبکه عصبی با STDP

## براساس نرخ و رمزگذاری ورودی زمانی

صفحه 1

این مقاله الگوریتم های یادگیری محلی را برای حل یک کار طبقه بندی با کمک مدل های ریاضی الهام گرفته از بیولوژیکی شبکه های عصبی اسپایک دار شامل مکانیسم انعطاف پذیری وابسته به زمان اسپایک (STDP) توسعه می دهد.

### شبکه های عصبی اسپایک

هنگامی که یک نورون فعال می شود ، سیگنالی تولید می کند که به نورون های متصل منتقل می شود و باعث افزایش یا کاهش پتانسیل غشای آنها می شود. در یک شبکه عصبی اسپایک ای ، وضعیت فعلی نورون به عنوان سطح فعال شدن آن تعریف می شود (به عنوان یک معادله دیفرانسیل مدل شده است).

از مزایای این مدل ها سادگی آنها و از این رو ، توانایی بالقوه پیاده سازی سخت افزار در دستگاه های محاسباتی بیومورفیک با مصرف انرژی کم است. روش های توسعه یافته بر اساس دو اثر کلیدی مشاهده شده در نورون ها با STDP است:

1. تثبیت سرعت شلیک
2. و حفظ الگوهای تکرار اسپایک.

در نتیجه ، دو الگوریتم برای حل یک کار طبقه بندی با شبکه عصبی spiking پیشنهاد شده است: اول بر اساس رمزگذاری نرخ داده های ورودی و دیگری بر اساس رمزگذاری زمانی. صحت الگوریتم ها با چندین ترکیب نرمال سازی داده های ورودی و پیش پردازش ، بر روی وظایف طبقه بندی معیار سرطان پستان فیشر Iris و ویسکانسین آزمایش می شود. دقت مربوطه 94٪ و 99٪ با معیار امتحان F1 است.

### . مقدمه

ارتباط مدل های یادگیری ساخت شبکه های عصبی اسپایک ای ای با انگیزه زیست شناختی به دلیل امکان استفاده از این مدل ها در دستگاه های محاسباتی نورومورفیک با مصرف برق بسیار کم برای حل مسایل عملی طبقه بندی است. چنین استفاده ای مستلزم تعبیه سه مولفه است:

\*نورومورفیک: مهندسی نورومورفیک ، همچنین به عنوان محاسبات نورومورفیک شناخته می شود ، استفاده از سیستم های یکپارچه سازی در مقیاس بسیار بزرگ شامل مدارهای الکترونیکی آنالوگ برای تقلید از ساختارهای عصبی بیولوژیکی موجود در سیستم عصبی است.

1. رمزگذاری داده های ورودی در الگوهای اسپایک برای ارائه به شبکه ،
2. مکانیسم انعطاف پذیری که تحت آن شبکه می آموزد الگوهای ورودی خود را تشخیص دهد و
3. رمزگشایی فعالیت اسپایک خروجی شبکه در برجسب های کلاس.

روش های رمزگذاری ورودی موجود را می توان به طور کلی به رمزگذاری نرخ یا زمانی تقسیم کرد ، جایی که اطلاعات با میانگین تعداد اسپایک ها در طی مدتی یا با زمان بندی دقیق اسپایک منتقل می شوند. رمزگذاری نرخ این مزیت را دارد که می توان بین عملکرد فعال

سازی یک نورون اسپایک دار (از نظر رابطه نرخ ورودی به نرخ خروجی) و یک نورون رسمی تشبیهی انجام داد که منجر به تهیه نقشه رسمی شبکه به یک اسپایک مشابه یکسان است. کدگذاری موقتی، به نوبه خود، به تعداد بیشتری اسپایک نیاز دارد، که امکان محاسبات سریعتر را فراهم می کند.

صفحه 2

برای هر دو روش رمزگذاری، سرعت و زمانی، تعدادی الگوریتم عملکرد خوب برای حل وظایف تشخیص الگو وجود دارد. دقت پیشرفته در تشخیص تصویر و طبقه بندی بردار واقعی با تطبیق انتشار مجدد خطا (BP) به شبکه های اسپایک یک لایه یا چند لایه به دست آمد. رویکردهای مبتنی بر BP، پیاده سازی یادگیری را به طور مستقیم بر روی تراشه دشوار می کند.

راه حل قابل توجه دیگر، شبکه های حالت مایع است، جایی که یک الگوی ورودی توسط یک مخزن بزرگ از سلول های عصبی با اتصالات عادی تصادفی (استاتیک یا پلاستیکی) پردازش می شود و در داخل مخزن، یک تغییر شکل مطلوب از الگوهای ورودی ظاهر می شود، که پس از آن باید توسط یک لایه بازخوانی استخراج شود.

لایه بازخوانی را می توان با الگوریتم های بهینه سازی معمولی آموزش داد یا با استفاده از قابلیت انعطاف پذیری ساختاری ایجاد کرد. در حالت دوم، هرچه الگوهای بیشتری وارد شوند، سلولهای عصبی بیشتری ایجاد می شوند، که همچنین برای پیاده سازی سخت افزار به سختی مقیاس پذیر است. در همین اثنا، تغییرات مختلف انعطاف پذیری سیناپسی Hebbian، مانند انعطاف پذیری وابسته به زمان-اسپایک (STDP)، که در آن دامنه تغییر وزن توسط برخی سیگنال های پاداش سراسری تعدیل می شود، ایجاد شد.

در قوانین یادگیری tempotron و BP-STDP، انعطاف پذیری از Hebbian به anti-Hebbian تغییر می یابد و بسته به نمونه داده ای که وارد می شود، دوباره برمی گردد. این قوانین به نویسندگان آنها این امکان را می دهد تا توابع هدف را که الگوریتم های آنها یک gradient descent را انجام می دهد، بدست آورند.

به طور کلی، در تمام آن الگوریتم های یادگیری، تغییر وزن سیناپسی توسط برخی از سیگنال های معلم اداره می شود که بر اساس ورودی و یا خروجی شبکه فعلی محاسبه می شود. این امر اجرای آنها را در دستگاه های به یادآوری، که از قوانین محلی انعطاف پذیری استفاده می کنند، پیچیده می کند.

این موضوع باعث تغییر توجه کانون توجه به STDP می شود، یک مدل انعطاف پذیری سیناپسی دراز مدت که از طریق آن الهام گرفته از زیست است و در آن تغییر وزن سیناپسی صرفاً به زمان اسپایک های پیش سیناپسی و پس سیناپسی بستگی دارد. نشان داده شده است که STDP در دستگاه های حافظه قابل اجرا است.

برای رمزگذاری نرخ، توانایی STDP در انجام شناسایی بدون نظارت 8 نشان داده شد:

یک لایه از سلولهای عصبی تحریکی، که با یکدیگر رقابت می کنند از طریق یک لایه اضافی از نورونهای مهارکننده غیرقابل کنترل، یاد گرفتند که ارقام دست نویس MNIST را با دقت 83٪ با یک شبکه 100-عصبی، و 87٪، 92٪ و 95٪ با 400 تشخیص دهند، به ترتیب 1600 و 6400 نورون.

برای رمزگذاری زمانی، یک اثر امیدوار کننده توانایی یک نورون با STDP در حفظ الگوهای تکرار اسپایک است:

هنگامی که الگوهای تکرار به نورون متناوب با سر و صدا ارائه می شود، سلول عصبی زودتر و زودتر می جهد. پاسخ به الگوها اما در دوره های ارائه سر و صدا به تدریج شلیک اسپایک ها را متوقف می کند. این اثر قبلاً برای تشخیص چهره از موتور 28 و بعداً برای شناسایی ارقام MNIST مورد استفاده قرار گرفته بود.

این مقاله ، در تلاش برای امکان پیاده سازی سخت افزار ، الگوریتم های یادگیری مبتنی بر STDP را برای کدگذاری ورودی و زمانی با حداکثر مدل نورونی و توپولوژی شبکه پیشنهاد می کند. الگوریتم ما برای رمزگذاری نرخ با یک مدل نورون ساده تر از کارهای موجود و حتی بیشتر ، با تعداد بسیار کم نورون کار می کند:

تعداد نورونهای مورد استفاده فقط برابر با تعداد طبقات است. برای رمزگذاری زمانی ، ما با تحریک یک نورون برای یادگیری الگوهای کلاس خود ، روش مبتنی بر حفظ الگو را بهبود می بخشیم. الگوریتم پیشنهادی برای رمزگذاری نرخ بر اساس خاصیت STDP قوی با میانگین تثبیت سرعت جهش ، 30 است که برای چندین مدل عصبی 31 و در طیف وسیعی از پارامترهای STDP نگهداری می شود 32: STDP منجر به وزن های سیناپسی می شود نورون با میانگین میانگین مشخصی جهش می کند. این نرخ به نرخ افزایش سن ورودی بستگی ندارد (به اندازه کافی گسترده) دامنه و فقط به پارامترهای نورون و STDP بستگی دارد. در بخش 2.5 ، ما از این اثر برای یک کار طبقه بندی استفاده می کنیم با آموزش هر نورون در کلاس خودش و سپس ایجاد تمایز در کلاس خودش از بقیه.

الگوریتم ما برای رمزگذاری زمانی ، که در بخش 2.4 شرح داده شده است ، شامل تحریک یک نورون برای شروع یک اسپایک در اوایل شروع ارائه یک الگوی از کلاس خود نورون است. در بخش 3 ، ما دقت طبقه بندی دو الگوریتم پیشنهادی را در ترکیب با تکنیک های مختلف پیش پردازش (که در بخش 2.2 توضیح داده شده است) در مورد دو وظیفه طبقه بندی معیار واقعی ارزیابی شده در بخش 2.6 مقایسه می کنیم: سرطان پستان 33 Fisher's Iris و 34 Wisconsin. نتایج در بخش 4 نشان می دهد که کارایی یادگیری برای هر دو الگوریتم مشابه است به شرطی که از پیش پردازش ورودی مناسب استفاده شود.

## 2 روش

برای هر دو روش رمزگذاری ورودی و دو ویژگی متناظر با STDP ، ما توپولوژی شبکه مربوطه ، الگوریتم یادگیری ، \* و روش رمزگشایی خروجی شبکه را به نتیجه طبقه بندی توصیف می کنیم. علاوه بر این ، ما تکنیک های مختلف پیش پردازش داده های ورودی را امتحان می کنیم.

## صفحه 3

ابت های مدل های عصبی و STDP و همچنین پارامترهای رمزگذاری ، برای هر راه اندازی با الگوریتم ژنتیک توصیف شده در ضمیمه A بهینه می شوند.

## 2.1 پیکربندی شبکه

برای هر دو کدگذاری ، شبکه یک لایه است و به تعداد کلاسها از سلولهای عصبی تشکیل شده است ، بنابراین به هر نورون یک کلاس اختصاص داده می شود (که بیشتر به عنوان کلاس خود نورون نامیده می شود). تفاوت در این است که ، برای رمزگذاری زمانی ، نورون ها با سیناپس های بازدارنده غیرپلاستیکی به یکدیگر متصل می شوند (شکل B1 را ببینید) به همین سادگی) برای رمزگذاری میزان ، نورون ها به یکدیگر متصل نیستند (شکل A 1 را ببینید).

در هر دو حالت ، این شبکه از نورون های نشتی یکپارچه و آتش (LIF) تشکیل شده است ، هر نورون پس از عبور از تمام مراحل پیش پردازش (به عنوان انتخاب شده از موارد ذکر شده در بخش 2.2).

### 2.1.1 مدل نورون

نورون یکپارچه و آتش (IF) به دلیل سادگی محاسباتی برای هر دو روش رمزگذاری انتخاب شده است. و در عین حال توانایی نمایش آن ، در صورت مجهز بودن به سیناپسهای STDP ، پدیده های لازم برای الگوریتم های یادگیری در نظر گرفته شده است: تثبیت سرعت و حفظ الگوهای تکرار. ما دو نوع از نورون IF را در نظر می گیریم: leaky35 و non-leaky.

مقایسه ترکیبات مختلف پیش پردازش ورودی برای هر دو میزان و کدگذاری زمانی با مدل LIF انجام می شود ، که در آن پتانسیل غشا  $V$  مطیع است. و به محض  $V - V_{th}$  ،  $V$  بلافاصله دوباره به  $V_{rest}$  بازنشانی می شود ، و نورون قادر به تغییر پتانسیل خود در طول دوره مقاوم در برابر Ref نیست. ما  $I_{syn}$  جریان پس سیناپسی از نوع نمایی را در نظر می گیریم

صفحه 4

که در آن  $\tau_{syn} = 5 \text{ ms}$  ،  $q_{syn} = 5 \text{ fC}$  ،  $w_i$  وزن سیناپس است و  $\Theta$  تابع مرحله Heaviside است. ثابت های عصبی  $V_{rest}$  ،  $\tau_m$  و  $C_m$  با کمک الگوریتم ژنتیک تنظیم می شوند ، دامنه های تنظیم و مقادیر یافت شده در جدول 2 ارائه شده است.

دامنه های تنظیم پارامتر ، و همچنین مقادیر ثابت (که در آن ذکر شده است) در جدول ، به یافته های اولیه ما مربوط می شود ، 36 ، جایی که جستجوی پارامترها به طور مستقل برای رمزگذاری نرخ و زمان انجام شد.

به منظور نشان دادن اینکه مدل حتی بیشتر ساده می شود ، ما همچنین مدل نوروئی IF را که دارای نشتی است بدون انعطاف پذیری ( $\tau_{ref} = 0$ ) و با جریان پس سیناپسی فرم تابع دلتا را امتحان می کنیم: پارامترهای قابل تنظیم عبارتند از: مانند بالا.

## 2.1.2 مدل Synapse

سیناپس های ورودی شبکه دارای STDP هستند که در آن یک وزن سیناپسی  $0 \leq w \leq w_{max} = 1$  با توجه به زمان نسبی اسپایک های پیش سیناپسی  $t_{pre}$  و اسپایک های پس سیناپسی  $t_{post}$  با  $\Delta w$  تغییر می کند:

ما از افزودنی STDP با  $\mu^+ + \mu^- = 0$  استفاده می کنیم ، در این صورت محدودیت اضافی برای جلوگیری از سقوط وزن زیر صفر یا بیش از حداکثر مقدار 1 مورد نیاز است:

در اینجا ، میزان یادگیری  $\alpha$  به میزان مجاز منابع محاسباتی تنظیم شده است: ما آن را روی 10-3 تنظیم می کنیم. پارامترهای  $\alpha$  ،  $\tau$  و  $\tau$  + با دامنه تنظیم و مقادیر موجود در جدول 2 قابل تنظیم هستند.

بخش مهمی از مدل STDP طرح 37 است که برای در نظر گرفتن  $astpre$  و  $t_{post}$  در قانون افزایش می یابد (1). برای رمزگذاری زمانی ، ما از رایج ترین طرح جفت شدن اسپایک همه به همه استفاده می کنیم ، جایی که هر اسپایک پس سیناپسی در آن است

در قاعده (1) با کلیه اسپایک های پیش سیناپسی قبلی در نظر گرفته شده و هر اسپایک پیش سیناپسی با تمام اسپایک های پیش سیناپسی قبلی جفت می شود. برای رمزگذاری نرخ ، ما از طرح متقارن نزدیکترین همسایه استفاده می کنیم ، زیرا این طرح قبلاً نشان داده شده بود که پدیده مورد استفاده را نشان می دهد - اثر تثبیت کننده میزان خروجی.

در طرح متقارن محدود ، یک tpost اسپایک پس سیناپسی با آخرین اسپایک tpre اسپایک پیش سیناپسی جفت می شود ، اما فقط در صورت وجود هیچ اسپایک پس سیناپسی یا پیش سیناپسی (از همان ورودی) دیگر بین tpre و tpost وجود ندارد. به طور مشابه ، اگر اسپایک دیگری بین آن وجود نداشته باشد ، اسپایک پیش سیناپسی با نزدیکترین اسپایک پس سیناپسی قبلی جفت می شود.

## 2.2 پیش پردازش ورودی

ما ترکیبات مختلفی از روشهای پیش پردازش ذکر شده در زیر را امتحان کرده ایم ، و سپس پیش پردازش شده را عبور می دهیم بردارهای یکی از دو رویکرد رمزگذاری است.

### 2.2.1 مقیاس کوچک

ممکن است انتظار داشته باشد که چنین پیش پردازشی در وظایفی مانند سرطان پستان فیشر Iris و ویسکانسین مفید باشد که دارای ویژگی های ورودی واقعی و احتمالاً در مقیاس متفاوت هستند.

### L2 2.2.2

هر بردار مقیاس بندی می شود تا هنجار اقلیدسی آن برابر با 1 باشد. معنای این پیش پردازش برای یک شبکه spiking با رمزگذاری نرخ این است که هر بردار ورودی شبکه را با تعداد کل اسپایک های یکسان در تمام سیناپس های ورودی تغذیه می کند.

### SBOEV ET AL 5

### 2.2.3 زمینه های پذیرای گوسی

بردار ورودی  $\vec{x}$  مجموعه داده  $X$  ، در اصل  $N$  بعدی ، به بردار ابعاد بالاتر  $N \cdot M$  تبدیل می شود

صفحه 5

ین پیش پردازش نوعی نرم افزاری از رمزگذاری جمعیت است که معمولاً در شبکه های چرخشی استفاده می شود

### 2.3 رمزگذاری ورودی

در رمزگذاری زمانی ، سیناپس ورودی  $i$ th مربوط به  $m$  component لایه  $x_i$  از یک بردار ورودی پردازش شده  $\vec{x}$  در لحظه  $T \cdot$  ( $x_i \max - x_i$ ) یک اسپایک دریافت می کند.

تفریق از حداکثر مقدار  $x_i \max$  از  $x_i$  روی همه بردارهای  $\vec{x}$  در اینجا معرفی می شود تا هرچه  $x_i$  بالاتر باشد ، اسپایک ورودی  $i$ th زودتر است. ما همیشه از رمزگذاری زمانی همراه با پیش پردازش توسط میدان های پذیرای گوس استفاده می کنیم. در رمزگذاری نرخ ، مولفه ورودی  $x_i$  با یک دنباله اسپایک پواسون (طول  $T$ ) با میانگین میانگین متناظر ارائه شده به سیناپس ورودی نورو با کدگذاری می شود. تبدیل یک مولفه بردار ورودی به ورودی نرخ اسپایک خطی است:  $x_i$  به  $\nu_{low} + x_i \cdot \nu_{high}$  نگاشت می شود ، به طوری که مقدار  $x_i 0$  با یک قطار اسپایک Poisson نرخ پایین  $\nu_{low}$  می شود و مقدار 1 با نرخ  $\nu_{low} + \nu_{high}$  کدگذاری می شود. در بعضی موارد ، ضرب ورودی ها انجام می شود ، به طوری که  $i$ th لایه  $\nu$  با  $\nu_{low}$  ،  $\nu_{high}$  توسط دسته ای از ورودی های  $K$  که قطارهای مستقل Poisson از همان نرخ  $\nu$  پایین  $\nu_{low} + x_i \cdot \nu_{high}$  در اینجا ، قرار است تکرار و  $K$  پارامترهای قابل تنظیم هستند. محدوده تنظیمات و مقادیر یافت شده آنها در جدول 2 ارائه شده است. قرار است تکرار

ورودی K-times برای مقابله با خاصیت 25 ماده افزودنی STDP برای آوردن وزن به یک توزیع دوبعدی، که در آن هر وزن به 0 یا حداکثر مقدار 1 گرایش دارد. رمزگذاری یک م component لفه ورودی توسط دسته ای از ورودی های با همان نرخ باعث می شود که مجموع وزنه های باند مذکور، وزن م of اثر م component لفه باشد، بنابراین اجازه می دهد تا وزن یک ملفه ورودی بتواند مقادیر میانی را بین 0 تا 1 بدست آورد.

## 2.4 الگوریتم یادگیری و رمزگشایی خروجی برای رمزگذاری زمانی

در مرحله اولیه، وزنه ها به حداکثر مقدار 1 تنظیم می شوند. همه سلولهای عصبی، کاملاً متصل به سیناپس های بازدارنده غیرپلاستیک، قطارهای اسپایک ورودی یکسانی را دریافت می کنند. در حین ارائه هر نمونه آموزش، نورون مربوط به کلاس نمونه توسط جریانی تحریک می شود، که باعث می شود نورون زودتر یک اسپایک خروجی شلیک کند. این امر به منظور تسهیل حفظ نمونه کدگذاری الگو است. در واقع، به دلیل STDP، چنین اسپایک ای زود هنگام باعث پاداش سیناپس هایی می شود که اسپایک های ورودی اولیه را دریافت می کنند (که مربوط به زمینه های پذیرایی مربوط به اجزای بردار ورودی فعلی است) و جریمه سیناپس هایی که اسپایک های ورودی بعدی را دریافت می کنند. این در نهایت باید منجر به تسهیل وزنه های سیناپسی شود که در پاسخ به نمونه های کلاس خود نورون باعث جهش زودرس می شوند.

در همان زمان، این اسپایک ناشی از تحریک از طریق اتصالات بازدارنده، اسپایک های دیگر سلولهای عصبی را سرکوب می کند، که قرار است حافظه آن نمونه را توسط سایر سلول های عصبی دلسرد کند. علاوه بر الگوهای اسپایک ای که نمونه های داده را رمزگذاری می کند، تمام ورودی ها نویز دریافت می کنند: توالی اسپایک های پواسون با فرکانس ثابت پایین.

در طول مرحله آزمایش، هر دو تحریک با جریان و صدای Poisson غیرفعال هستند. کلاس نمونه آزمایشی تعیین می شود که توسط کدام نورون در هنگام ارائه نمونه اولین اسپایک منتشر شود.

## 2.4.1 الزامات پارامتر الگوریتم یادگیری برای رمزگذاری زمانی

این قانون رمزگشایی اسپایک اول بیانگر این است که فقط آن سیناپس های ورودی زنده می مانند که الگوهای کلاس خود آنها را تغذیه می کنند. اسپایک های اولیه، در حالی که وزن تمام سیناپس های باقی مانده در نهایت کاهش می یابد. از این رو، ملاحظات زیر:

برای تنظیم پارامتر:

1. ظرفیت غشا سانتی متر، آستانه  $V_{th}$ ، و استراحت بالقوه  $V_{rest}$  باید تعداد ورودی ها را در خود جای دهد، هر ورودی در هنگام ارائه یک الگو یک اسپایک دریافت می کند.

2. دوره مقاومت نسبی نورون باید برابر یا بیشتر از الگوی زمان ارائه باشد، به طوری که فقط یک خروجی وجود دارد. اسپایک در هنگام ارائه یک الگوی ورودی شلیک می شود. به این ترتیب، هنگامی که الگوی از کلاس خود یک نورون ارائه می شود، اسپایک خروجی اولیه ناشی از تحریک منجر به تقویت اسپایک های ورودی اولیه می شود، در حالی که طولانی دوره نسوز تضمین می کند که هیچ جهش خروجی دیگری رخ نمی دهد و بنابراین هیچ ورودی دیگری تسهیل نمی شود.

3. پارامترهای STDP باید به سمت افسردگی بیشتر منتقل شوند تا از تسهیل وزن تا آنجا که جلوگیری شود. ممکن است وقتی یک نورون الگویی ارائه نمی شود که از کلاس خودش نباشد. زمان ثابت افسردگی  $-\tau$  باید باشد، بالاتر از ثابت زمان تسهیل  $\tau + \tau$  باید با الگوی ارائه زمان مقایسه شود، در حالی که  $-\tau$  باید از دوره نویز پواسون که بین الگوهای ورودی ارائه شده است، استقبال کند. به این ترتیب، تمام ورودی ها افزایش می یابد و دیرتر از اوج خروجی، از جمله نویز بین الگوی پواسون، در رکود STDP محاسبه می شود. سیناپسهایی را که به آنها می آیند، ضعیف کنید.

ملاحظات فوق به فرد امکان می دهد پارامترهای نورون و STDP را فقط بر اساس الگوی ارائه شده انتخاب کند. مدت زمان T و فاصله بین الگوی  $\tau_{th}: \tau_{ref} = \tau_{th} - T$  ،  $\tau_m = T$  ،  $\tau_+ = T$  ،  $\tau_- = \tau_{th} + T$  . رفع خودسرانه  $V_{th} = 1$  an

صفحه 6

25. الگوریتم یادگیری و رمزگشایی خروجی برای رمزگذاری نرخ

نورون های شبکه به یکدیگر متصل نیستند. در مرحله آموزش ، هر نورون فقط نمونه هایی از کلاس خود را دریافت می کند. سپس ، یک نورون قرار است در پاسخ به بردارهایی که آموزش دیده است ، میزان متوسط خروجی پایدار ایجاد کند. سپس از این نرخ به عنوان نشانگر برای تشخیص کلاس خود نورون استفاده می شود. قبل از تمرین ، وزنه ها با مقادیر تصادفی به طور یکنواخت از 0 تا 1 توزیع می شوند. ما وقتی تمرین را متوقف می کنیم. هر وزن یا با توجه به معیار رسیدن به ثابت بودن وزنها ، به زیر 1/0 یا بالاتر از 9/0 می رسد. توزیع bimodal25 ، و دلهره تصادفی بیشتر آنها تأثیر قابل توجهی در میزان اسپایک خروجی نخواهد داشت.

در مرحله آزمایش ، STDP غیرفعال است (از نظر فنی ، با تنظیم  $\lambda = 0$ ) ، و همه سلول های عصبی نمونه هایی از مجموعه آموزش و آزمایش از همه کلاس ها ارائه می شود. یک نمونه x از مجموعه تست به کلاس  $k = \text{argmin} | \text{outk}(x) - \text{outk}(\text{Classk}) |$  اختصاص داده می شود ، که در آن  $\text{outk}(x)$  اسپایک است. نرخ نورون k در پاسخ به بردار ورودی x ، و  $\text{outk}(\text{Classk})$  میانگین نرخ نورون k را نسبت به همه نشان می دهد.

نمونه هایی از مجموعه آموزش کلاس k. ما بیشتر آن را قانون رمزگشایی نرخ بهره خود می نامیم.

2.5.1 الزامات پارامتر الگوریتم یادگیری برای رمزگذاری نرخ

یادگیری موفقیت آمیز با الگوریتم ارائه شده در بالا برای رمزگذاری نرخ به شرایط زیر بستگی دارد:

1. اثر تثبیت کننده سرعت خروجی باید برای ثابت های STDP داده شده ، پارامترهای مدل نورون و مقیاس داده شده از نرخ افزایش ورودی وجود داشته باشد. با تنظیم ثابت های STDP و نورون می توان به این مهم دست یافت.

2- برای STDP وزنه های سیناپسی ایجاد کند که نورون با آن میانگین سرعت خروجی مشابهی در پاسخ به آنها ساطع کند

تمام نمونه های کلاس خود نورون ، حداقل چنین وزنه هایی باید وجود داشته باشد. این نیاز به عادی سازی ورودی و یا پیش پردازش مناسب دارد.

3- برای اینکه یک نورون آموزش دیده در مرحله آزمایش کلاس خود را از کلاسهای دیگر متمایز کند ، این کلاسهای دیگر باید

متفاوت با سرعت شلیک پایدار در کلاس نورون ، باعث می شود که آن با برخی از میانگین های دیگر شلیک شود. ما با تنظیم پارامترهای رمزگذاری ورودی و با جستجوی پیش پردازش ورودی بهینه به این هدف می رسیم.

2.6 مجموعه داده ها

2.6.1 زنبق فیشر

مجموعه داده + موجود در مخزن UCI39 شامل 150 گل است که در چهار ویژگی توصیف شده است - طول و عرض گل ماسوره و گلبرگ به سانتی متر. گلهای سه کلاس تقسیم می شوند که در هر کلاس 50 کلاس وجود دارد: Iris ، Iris setosa canadensis

virginica و Iris versicolor. کلاس اول به طور خطی از طبقه دوم و سوم قابل تفکیک است ، در حالی که طبقه دوم و سوم به طور خطی قابل تفکیک نیستند.

## 2.6.2 سرطان پستان ویسکانسین

صفحه 7

مجموعه داده های سرطان پستان  $\times$  جمع آوری شده در دانشگاه ویسکانسین شامل 569 نمونه ، 357 کلاس "خوش خیم" و 212 "بدخیم" است. ویژگی ها از طریق یک تصویر دیجیتالی از یک سوزن ظریف از توده پستان محاسبه می شود. هسته سلول در تصویر با ده ویژگی مشخص می شود: شعاع ، بافت ، محیط ، مساحت ، صافی ، فشردگی ، تقعر ، نقاط مقعر ، تقارن و بعد فراکتال. بردار ورودی شامل میانگین ، انحراف معیار و بدترین مقادیر در تمام هسته ها برای هر یک از ویژگی ها است ، از این رو مجموع 30 ویژگی است.

### 3 تجربه

آزمایش های زیر برای ساخت یک الگوریتم طبقه بندی کارآمد انجام شده است که شامل پیش پردازش داده ها ، کدگذاری و روش های یادگیری و رمزگشایی است. ترکیبات مختلف گزینه های نرمال سازی که در بخش 2.2 — L2 ، مقیاس کوچک و L2 شرح داده شده است. minmaxscale - در نظر گرفته شده است ، به صورت اختیاری با پردازش با زمینه های پذیرای گوسی دنبال می شود. داده ها ، به روشی یا روش دیگر از پیش پردازش شده ، سپس به یکی از الگوریتم های یادگیری ، یکی برای رمزگذاری نرخ یا دیگری برای رمزگذاری زمانی ، منتقل می شوند.

به منظور ارزیابی جداگانه اثرات نمایش داده های مختلف - بردارهای اولیه خام ، یا بردارهای پیش پردازش شده با روش های ذکر شده در بالا ، یا داده های پردازش شده توسط یک شبکه اسپایک دار آموزش دیده - در شرایط رمزگشایی برابر ، دقت طبقه بندی Gradient Boosting \$ را از کتابخانه scikit-learn40 در داده های اولیه اولیه و داده های از پیش پردازش شده به روش های مختلف . علاوه بر این ، به منظور ارزیابی بهره وری از نرخ خود قانون رمزگشایی که در بخش 2.5 برای SNN رمزگذار نرخ تهیه شده است ، با رمزگشایی Gradient Boosting مقایسه می شود .

دومی در مورد میزان اسپایک خروجی که SNN آموزش دیده در پاسخ به مجموعه آموزش ساطع می کند ، آموزش داده می شود و سپس برای پیش بینی کلاسهای آزمایش نمونه ها را با توجه به نرخ خروجی SNN در پاسخ به آنها تنظیم می کنیم. در مورد SNN رمزگذار زمانی ، قانون رمزگذاری اولین اسپایک آن به اندازه کافی ساده به نظر می رسد ، به همین دلیل آزمایشات با افزایش شیب فقط از نظر مقایسه با نمایش داده های اولیه مفید است.

تنظیم پارامترهای SNN - ثابت های مدل عصبی و STDP و همچنین پارامترهای رمزگذاری ورودی - توسط الگوریتم ژنتیک MultiNEAT41 توصیف شده در ضمیمه A انجام می شود. آموزش شامل اعتبار سنجی پنج برابر است.

علاوه بر این ، به منظور بررسی مقاومت مدل به وزنه های تصادفی اولیه سیناپسی ، ما یادگیری را برای بهترین ترکیبات پیش پردازش ورودی پنج بار تکرار می کنیم و می بینیم که تفاوت دقت اجرا از اجرا کمتر از انحراف آن برابر چینهای اعتبار متقابل است. بعد از اینکه پیش پردازش بهینه پیدا شد ، آن را ثابت کرده و تأثیر ثابت های مدل SNN را مطالعه می کنیم. برای اینکه بفهمیم پارامترهای نورون و STDP برای هر دو الگوریتم یادگیری و هر دو وظیفه طبقه بندی مشترک وجود دارد ، آنها را به جای اینکه از نظر ژنتیکی تنظیم کنیم ، ثابت می کنیم: برای رمزگذاری زمانی ، آنها را مطابق با ملاحظات بخش 2.4.1 انتخاب می کنیم ، و برای رمزگذاری نرخ ، ثابت های نورون را برابر با کدگذاری زمانی قرار می دهیم.



سرانجام ، برای اینکه نشان دهیم مدل نورو می تواند حتی بدون کاهش دقت قابل توجه حتی بیشتر ساده شود ، ما اجرا می کنیم.تنظیم پارامتر و یادگیری جدید برای بهترین پیکربندی پیش پردازش ورودی ، جایگزینی مدل نورو LIF با یکپارچه ساز غیر نشتی توصیف شده در بخش 2.1.1

#### 4 نتیجه و بحث

تقویت گرادیان ، هنگامی که یا روی داده های خام یا داده های پیش پردازش شده آموزش ببینید (به "افزایش گرادیان" در ستون مراجعه کنید)"یادگیری" (در جداول B1 و B2) ، فارغ از تکنیک های رمزگذاری و پیش پردازش ، دقت کاملاً یکسانی را نشان می دهد.این نشان می دهد که داده ها بدون توجه به پیش پردازش ، آموزنده و قابل یادگیری هستند. در مورد شبکه های اسپایک ، پردازش با زمینه های گیرنده گوسی یک نیاز ضروری برای دقت بالا است. شبکه ماریچ دارای رمزگذاری زمانی با نرمال سازی L2 در وظیفه Iris و با مقیاس کوچک در وظیفه سرطان پستان ، بهترین دقت خود را به دست می آورد (به "SNN با رمزگذاری زمانی" در جدول 1 مراجعه کنید). به طور مشابه ، اگر شبکه داده های مربوط به هر دو وظیفه با کوچکترین مقیاس نرمال سازی شده و از قبل با زمینه های پذیرش پردازش شوند ، شبکه spiking با کدگذاری نرخ به بهترین دقت خود می رسد.

ترکیب پیش پردازش که هر دو الگوریتم SNN با آن دقت کلی معقولی را ایجاد می کنند.در هر دو وظیفه طبقه بندی L2 با مقیاس کوچک پس از آن و پس از آن زمینه های پذیرش است. با پیش پردازش بهینه ، قانون رمزگشایی "نرخ خود" که برای SNN با کدگذاری نرخ تهیه شده است ، به همان دقت دست می یابد. به عنوان رمزگشایی توسط Gradient Boosting (به "افزایش گرادیان" در ستون "رمزگشایی" جداول 1 ، B1 و B2 مراجعه کنید). این یعنی که قانون رمزگشایی ما برای رمزگشایی نرخ می تواند اطلاعاتی را که یک شبکه اسپایک آموزش دیده در خروجی خود انتقال می دهد ، با دقت استخراج کند.

#### صفحه 8

برای مقایسه ، جدول 1 همچنین تعدادی از نتایج پیشرفته سایر شبکه های عصبی رسمی و جهشی موجود را ذکر می کند.

مقایسه ، با این حال ، به دلیل عدم اعتبار سنجی متقابل در نتایج ادبیات پیچیده است. پارامترهای SNN بدست آمده توسط الگوریتم ژنتیک برای بهترین پردازش در ستونهای "مجموعه 1" در جدول 2 ارائه شده است. ضریب رمزگذاری نرخ بالا تمایل دارد زیاد باشد زیرا نرخ ورودی بالاتر منجر به تولید بالاتر می شود ، که تفاوت در پاسخ نوروها به طبقات مختلف را بیشتر نمایان می کند. برعکس ، قسمت ثابت نرخ ورودی ، پایین ، نزدیک به صفر یافت می شود.

با ثابت بودن نورو و STDP (همانطور که در ستون "تنظیم 2" در جدول 2 ارائه شده است) به جای اینکه از نظر ژنتیکی تنظیم شود ، دقت (سطرهای "ثابتهای عصبی ثابت شده در جدول 1") در واقع همان مواردی است که با تنظیمات ژنتیکی تنظیم شده است ، که نشان می دهد که در واقع می توان از نیاز به تنظیم پارامترهای نورو و STDP برای هر کار طبقه بندی مربوط جلوگیری کرد. بنابراین می توان با تعدیل بر تعداد و مقیاس اجزای ورودی در وظیفه مورد نظر ، عمل کرد. پارامترهای رمزگذاری ورودی پایین ، بلند ، مدل ساده نورو IF بدون نشتی در مقایسه با نورو LIF دقت را مختل نمی کند:

نتایج نشان داده شده SNN از نورو های IF" در جدول 1 با نتایج "SNN" متفاوت بیش از محدوده انحراف است.

#### 5 نتیجه گیری

هر دو الگوریتم یادگیری ، اولین مورد با کدگذاری نرخ که براساس اثر تثبیت نرخ است و دیگری با رمزگذاری زمانی که براساس اثر حفظ الگو است ، خود را قادر به حل یک کار طبقه بندی نشان می دهند. با پیش پردازش ورودی توسط زمینه های گیرنده گوسی ، حتی یک مدل ساده مانند شبکه یک لایه از سلول های عصبی IF به F1 نمره 99٪ در مجموعه داده Iris فیشر و 94٪ در مجموعه داده سرطان پستان ویسکانسین دست می یابد ، که قابل مقایسه با دقت به روز شبکه های عصبی مصنوعی چند لایه. این واقعیت که برای هر دو الگوریتم یادگیری ، دو مجموعه متفاوت از پارامترها اساساً از یک دقت برخوردارند ، نشان می دهد که هر دو الگوریتم نسبت به

یک طیف گسترده منطقی از ثابت های نورو و مدل STDP قوی هستند. پارامترهای رمزگذاری ورودی ، باید برای هر کار طبقه بندی خاص تنظیم شوند.

سادگی شبکه ، همراه با نوع افزودنی STDP با طرح جفت شدن اسپایک نزدیکترین همسایه که از آن استفاده می کنیم ، امکان پیاده سازی مدل های پیشنهادی را در دستگاه های یادآوری فراهم می کند. با این حال ، کار بیشتری لازم است تا اطمینان حاصل شود که استحکام الگوریتم یادگیری دقیقاً قابل انعطاف است که در چنین دستگاه هایی مشاهده می شود.